#### T-SA:

Twitter keyword Search API based Tweet Analysis (트위터 키워드 검색 API기반 트윗 분석)

```
파 목 산학캠스톤디자인1(2019-1학기)
담당교수 정현숙교수님
팀 명 브이아이(VI)
발표와 자서재의
발표일자 2019.04.04
```

# T-SA: Contents Twitter Keyword Search API based Tweet Analysis


- 1. T-SA: Team Introduction
- 2. T-SA: Purpose of Development
- 3. T-SA: Development Environment
- 4. T-SA: Program Flowchart
- 5. T-SA: Development Schedule
- 6. T-SA: Weekly Progress
- 7. T-SA: Github

### T-SA: Team Introduction

Twitter Keyword Search API based Tweet Analysis



| Name       | Lee SeokJune  |
|------------|---|
| Student ID | 20165072  |
| Cell Phone | 010-4020-5717   |
| E-mail     | op2se1@gmail.com  |
| Major Lang | Java  |
| GitHub     | https://github.com/SeokJune                             |
|            |   |
| Part       | - MariaDB 환경 구축 및 관리<br>- Hadoop(Map)구현<br>- 문서 작성 및 수정 |



| Name       | Lee YunHyuck   |  |  |  |  |  |  |
|------------|--|--|--|--|--|--|--|
| Student ID | 20165062   |  |  |  |  |  |  |
| Cell Phone | 010-4220-5134  |  |  |  |  |  |  |
| E-mail     | leeyh5134@naver.com  |  |  |  |  |  |  |
| Major Lang | Python   |  |  |  |  |  |  |
| GitHub     | https://github.com/yunhyuck  |  |  |  |  |  |  |
| Part       | - Hadoop3 환경 구축<br>- Hadoop, DB 연동 구현<br>- Sqoop 환경 구축<br>- Hadoop(Reduce)구현 |  |  |  |  |  |  |



| Acres      |  |
|------------|--|
| Name       | Bae InGyu                                |
| Student ID | 20165073                                 |
| Cell Phone | 010-4679-4968                            |
| E-mail     | happykkk789@naver.com                    |
| Major Lang | Python                                   |
| GitHub     | https://github.com/BaeInGyu              |
|            |  |
| Part       | - Python, DB 연동 구현<br>- Vigualization 그형 |

- Visualization 구현




| 1          |  |
|------------|--|
| Name       | Seo JaeIck                             |
| Student ID | 20144773                               |
| Cell Phone | 010-2460-7617                          |
| E-mail     | nero8879@naver.com                     |
| Major Lang | Python                                 |
| GitHub     | https://github.com/nero8879            |
|            |  |
| Part       | - Twitter API 구현<br>- Visualization 구현 |

#### T-SA: Purpose of Development


대한민국 지역 및 특정 기간에 사용된 키워드 트렌드 분석


특정 인물의 트윗 스타일 분석














**Twitter** Keyword Search API based Tweet Analysis



To execute Python and Hadoop

Ubuntu Site:

- https://www.ubuntu.com/

Twitter Keyword Search API based Tweet Analysis



Provides tweepy which is twitter API

Visualization of Data

Python Stie:


- https://www.python.org/

민형기, 파이썬으로 데이터 주무르기, 2017.12.29, 비제이퍼블릭

파이썬으로 데이터 주무르기 저자의 블로그 중 파이썬 목록

- https://pinkwink.kr/category/Software/Python

**Twitter** Keyword Search API based Tweet Analysis




Open source RDBMS

Based on the same source as MySQL

MariaDB Stie:

- https://mariadb.com/kb/ko/mariadb

**Twitter** Keyword Search API based Tweet Analysis



Distributed storge and Processing of big data

Pseudo-distributed

Hadoop Site:

- https://hadoop.apache.org/

정재화, 시작하세요! 하둡 프로그래밍 빅데이터 분석을 위한 하둡 기초부터 YARN까지[개정2판], 2016.05.13, 위키북스


분산 메세지 처리

(Kafka)

#### Using Hadoop Ecosysytem

스트리밍 데이터 수집

(Chuckwa, Flume, Scribe)



DBMS 데이터 수집

(Sqoop, Hiho)

#### Sqoop

- RDBMS에서 데이터 수집
- 배치 처리 후 RDBMS에 데이터 저장


#### HDFS

- 분산 데이터 저장

#### Map/Reduce

- 분산 데이터 배치 처리

**Twitter** Keyword Search API based Tweet Analysis




Used in Hadoop and Sqoop

OpenJDK Site:

- https://openjdk.java.net/

Twitter Keyword Search API based Tweet Analysis



To Create Map/Reduce for Hadoop

Eclipse Site:

- https://www.eclipse.org/

**Twitter** Keyword Search API based Tweet Analysis



To import data from Twitter

Twitter Developer Site:

- https://developer.twitter.com


Tweepy Site:

- http://www.tweepy.org

Twitter Analysis Site:

- http://tweetrend.com/
- https://foller.me/

#### Importing Twitter API Key



Get Started 를 누르면 아래와 같이 Twitter API를 사용하기 위한 인증키 발급을 받을 수 있는 목록을 받을 수 있다. Create an app 을 제외한 나머지는 유료 이므로 무료로 사용하기 위한 인증키를 발급 받는다.

#### Importing Twitter API Key

#### Tell us how this app will be used (required)

This field is only visible to Twitter employees. Help us understand how your app will be used. What will it enable you and your customers to do?

이 앱의 사용방법은 사용자의 키워드를 분석하여, 해당 키워드에 대해 분석을 통해 얻을 수 있는 정보들에 대해 시각화 하는 것에 목적이 있 습니다.


① Must be 100 characters or longer

Minimum characters: 100

앱의 이름, 앱의 설명, 사용하는 주소, 앱의 사용 방법에 대한 필수적인 요소를 작성합니다.


TWICE They word bearenth I based I weet Intary

#### Importing Twitter API Key




개인 정보의 Apps를 통해 본인이 사전에 작성한 제목을 통해API 키가 발급이 된 것을 확인 할 수 있다.

# T-SA: Program Flowchart Twitter Keyword Search API based Tweet Analysis



### T-SA: Program Flowchart\_W04

Twitter Keyword Search API based Tweet Analysis



### T-SA: Program Flowchart(1)\_W04

Python에서 제공하는 TwitterAPI인 Tweepy를 이용한 데이터 크롤링

Search API를 이용한 키워드 관련 데이터 검색

Timeline API를 이용한 유저 관련 데이터 검색

### T-SA: Program Flowchart(2)\_W04

크롤링된 데이터를 MariaDB에 저장

### T-SA: Program Flowchart(3)\_W04

MariaDB에 저장된 데이터를 Sqoop을 이용해 HDFS에 분산 저장 처리

### T-SA: Program Flowchart(4)\_W04

Map/Reduce를 이용해 분산 데이터 배치 처리

### T-SA: Program Flowchart(5)\_W04

분산 배치 처리된 데이터를 Sqoop을 이용해 MariaDB로 저장

### T-SA: Program Flowchart(6)\_W04

(5)과정을 통해 저장된 데이터를 Python에 로드

### T-SA: Program Flowchart(7)\_W04

Python에서 제공되는 시각화 라이브러리를 이용한 데이터 시각화

# T-SA: Development Schedule Twitter Keyword Search API based Tweet Analysis

|   | 1 | 2 | 3 | 4 | 5 | 6 | 7 | 8 | 9 | 10 | 11 | 12 | 13 | 14 | 15 |
|---|---|---|---|---|---|---|---|---|---|----|----|----|----|----|----|
| Conference                                |   |   |   |   |   |   |   |   |   |    |    |    |    |    |    |
| Create document and PPT                   |   |   |   |   |   |   |   |   |   |    |    |    |    |    |    |
| Create class of Twitter API in Python     |   |   |   |   |   |   |   |   |   |    |    |    |    |    |    |
| Create control class of MariaDB in Python |   |   |   |   |   |   |   |   |   |    |    |    |    |    |    |
| Tasking of HDFS                           |   |   |   |   |   |   |   |   |   |    |    |    |    |    |    |
| Tasking of Map/Reduce                     |   |   |   |   |   |   |   |   |   |    |    |    |    |    |    |
| Normalized data save to MariaDB           |   |   |   |   |   |   |   |   |   |    |    |    |    |    |    |
| Visualization through by Python           |   |   |   |   |   |   |   |   |   |    |    |    |    |    |    |
| Test and Modification of T-SA             |   |   |   |   |   |   |   |   |   |    |    |    |    |    |    |



Lee SeokJune



Lee YunHyuck



Bae InGyu



Seo JaeIck

문서 작성 및 수정 HIVE 관련 자료 수집 HIVE-RDB 연동 자료 수집

문서 작성 및 수정 MariaDB 자료 수집 HIVE-RDB 연동 자료 수집

Twitter API 자료 수집, 정리 및 간단한 예제 테스트

발표 준비

Twitter API 자료 수집, 정리 및 간단한 예제 테스트

# T-SA: Weekly Progress\_W04 Twitter Keyword Search API based Tweet Analysis





Lee YunHyuck



Bae InGyu



Seo JaeIck

문서 작성 및 수정 MariaDB 구축

Sqoop 구축 DB, Hadoop 연동

Python, MariaDB 연결 및 DML(select, delete) 구현

발표 준비

Sqoop

Hadoop 1.2.1

#### hadoop@ubuntu-VirtualBox:~\$ jps 18320 SecondaryNameNode 18881 Jps 18072 NameNode 18394 JobTracker 18558 TaskTracker

Hadoop 3.2.0

```
yunhyuck@yunhyuck:~$ jps
3666 NodeManager
3079 SecondaryNameNode
2839 DataNode
2666 NameNode
3470 ResourceManager
3807 Jps
```

#### JobTracker

- 클러스터 전체의 리소스 관리, 잡 스케쥴링 및 모니터링 기능 -> ResourceManager

#### TaskTracker

- slave node에서 map reduce작업을 수행 -> NodeManager

Sqoop 실행

```
yunhyuck@yunhyuck: vunhyuck
Warning: /home/yunhyuck/sqoop1/sqoop-1.4.7/../hbase does not exist! HBase imports will fail.
Please set $HBASE HOME to the root of your HBase installation.
Warning: /home/yunhyuck/sgoop1/sgoop-1.4.7/../hcatalog does not exist! HCatalog jobs will fail.
Please set $HCAT HOME to the root of your HCatalog installation.
Warning: /home/yunhyuck/sqoop1/sqoop-1.4.7/../accumulo does not exist! Accumulo imports will fail.
Please set $ACCUMULO HOME to the root of your Accumulo installation.
Warning: /home/yunhyuck/sqoop1/sqoop-1.4.7/../zookeeper does not exist! Accumulo imports will fail.
Please set $ZOOKEEPER HOME to the root of your Zookeeper installation.
/home/yunhyuck/hadoop/libexec/hadoop-functions.sh: 줄 2364: HADOOP_ORG.APACHE.SQOOP.SQOOP_USER: bad substitution
/home/yunhyuck/hadoop/libexec/hadoop-functions.sh: 줄 2459: HADOOP_ORG.APACHE.SQOOP.SQOOP_OPTS: bad substitution
Try 'sgoop help' for usage.
```

#### Sqoop Job 실행

sqoop import --connect "jdbc:mysql://localhost/yunhyuck" --username yunhyuck -P --table "test" -m 1


```
2019-04-03 17:31:10,195 INFO mapreduce.Job: Running job: job_1554280042468_0001
2019-04-03 17:31:22,362 INFO mapreduce.Job: Job job_1554280042468_0001 running in uber mode : false
2019-04-03 17:31:22,363 INFO mapreduce.Job: map 0% reduce 0%
2019-04-03 17:31:32,455 INFO mapreduce.Job: map 100% reduce 0%
2019-04-03 17:31:33,474 INFO mapreduce.Job: Job job 1554280042468_0001 completed successfully
2019-04-03 17:31:33,553 INFO mapreduce.Job: Counters: 33
       File System Counters
               FILE: Number of bytes read=0
               FILE: Number of bytes written=232265
               FILE: Number of read operations=0
               FILE: Number of large read operations=0
               FILE: Number of write operations=0
               HDFS: Number of bytes read=87
               HDFS: Number of bytes written=2
               HDFS: Number of read operations=6
               HDFS: Number of large read operations=0
               HDFS: Number of write operations=2
               HDFS: Number of bytes read erasure-coded=0
       Job Counters
               Launched map tasks=1
               Other local map tasks=1
               Total time spent by all maps in occupied slots (ms)=7400
               Total time spent by all reduces in occupied slots (ms)=0
               Total time spent by all map tasks (ms)=7400
               Total vcore-milliseconds taken by all map tasks=7400
                Total megabyte-milliseconds taken by all map tasks=7577600
```

```
Map-Reduce Framework
               Map input records=1
               Map output records=1
                Input split bytes=87
               Spilled Records=0
               Failed Shuffles=0
               Merged Map outputs=0
               GC time elapsed (ms)=57
               CPU time spent (ms)=1060
               Physical memory (bytes) snapshot=194822144
               Virtual memory (bytes) snapshot=2671808512
               Total committed heap usage (bytes)=173015040
               Peak Map Physical memory (bytes)=194822144
               Peak Map Virtual memory (bytes)=2671808512
       File Input Format Counters
               Bytes Read=0
       File Output Format Counters
               Bvtes Written=2
2019-04-03 17:31:33,558 INFO mapreduce.ImportJobBase: Transferred 2 bytes in 29.6853 seconds (0.0674 bytes/sec)
2019-04-03 17:31:33,561 INFO mapreduce.ImportJobBase: Retrieved 1 records.
```


#### Sqoop Job 결과 확인

http://localhost:9870/

#### **Browse Directory**



#### Sqoop Job 상세 결과 확인



# Python(DB)

**Twitter** Keyword Search API based Tweet Analysis

#### DBModule.selectDB

```
# 테이블의 데이터 모두조회
def selectDB (table) :
       # MariaDB연결 및 Cursor 생성
       conn = dbModule.dbconn()
       curs = conn.cursor()
       # 테이블 조회
       sql = "select * from "+table+";"
       curs.execute(sql)
       # 테이블 데이터출력
       i = 0
       rows = curs.fetchall()
       result = rows
       # Select종료시 MariaDB연결종료
       conn.close()
       return print("조회완료\n", result)
```

```
vi@vi-X510UQR:~/다운로드$ python3 dbMain.py
데이터 모두 조회할 테이블명 입력: Student
조회완료
((1, 'Kim', '010-0000-0001', 'Computer', 'A'), (2, 'Lee', '010-0000-0002', 'Computer', 'A+'), (3, 'Pack', '010-0000-0003', 'Computer', 'C+')
, (4, 'Oḥ', '010-0000-0004', 'Computer', 'B'), (5, 'Song', '010-0000-0005', 'Computer', 'F'), (6, 'Yoon', '010-0000-0006', 'Computer', 'D'))
```

Twitter Keyword Search API based Tweet Analysis


#### DBModule.deleteDB

```
# 테이블의 데이터 모두삭제
def deleteDB (table) :
       # MariaDB연결 및 Cursor 생성
       conn = dbModule.dbconn()
       curs = conn.cursor()
       # Data삭제
       sql = "delete from "+table+";"
       curs.execute(sql)
       conn.commit()
       # Connection 닫기
       conn.close()
       return print("삭제완료")
```

데이터 전부 삭제할 테이블명 입력: Student MariaDB [mysql]> select \* from Student; 삭제완료 Empty set (0.00 sec)




#### Project Github URL: https://github.com/SeokJune/BigData\_VI\_T-SA/



# T-SA: Github\_W04 Twitter Keyword Search API based Tweet Analysis

Project Github URL: https://github.com/SeokJune/BigData\_VI\_T-SA/



# Q&A

Thank you.